

BÁO CÁO PHÂN TÍCH BẢN CHẤT & KIẾN TRÚC RAG NÂNG CAO

Buổi 14: Hybrid Search + Cross-Encoder Reranking & Mini Knowledge Graph

1. BÀI TOÁN THỰC TẾ: VÌ SAO RAG TRUYỀN THÔNG THẤT BẠI?

Khi xây dựng trợ lý AI tra cứu văn bản quy phạm pháp luật hoặc quy định ngân hàng, các hệ thống RAG cơ bản thường gặp hai hạn chế lớn:

- Nếu chỉ dùng Dense Vector: Hiểu ý nghĩa khái quát nhưng dễ bỏ sót các từ khóa chính xác như số hiệu văn bản (Thông tư 01/2014), số điều (Điều 24), hoặc tên biểu mẫu.
- Nếu chỉ dùng BM25 Keyword: Bắt từ khóa chuẩn nhưng nếu người dùng hỏi bằng từ đồng nghĩa (ví dụ: 'duyet cho vay' thay vì 'thẩm quyền cấp tín dụng') thì BM25 sẽ bỏ qua hoàn toàn.

□ GIẢI PHÁP BUỔI 14: Kết hợp Hybrid Search (BM25 + Dense) bằng thuật toán RRF, chấm điểm lại bằng Cross-Encoder Reranker và bổ trợ cấu trúc từ Knowledge Graph Neo4j.

2. MỤC ĐÍCH & KẾT QUẢ ĐẠT ĐƯỢC CỦA TỪNG BƯỚC

Bước thực hiện	Mã nguồn	Mục đích kỹ thuật & nghiệp vụ	Kết quả thực tế đạt được
1. Chuẩn hóa Corpus	prepare_corpus.py	Làm sạch HTML, tách văn bản thành từng Điều khoản, gán mã định danh duy nhất và tạo Citation xuất xứ.	Tạo file chunks_normalized.csv gồm 1.295 chunks từ 15 văn bản làm nguồn chuẩn dùng chung.
2. BM25 & Dense Baseline	bm25_retriever.py dense_retriever.py	Xây 2 bộ lọc độc lập: BM25 bắt từ khóa cứng; Dense Vector hiểu ngữ nghĩa qua mô hình ngôn ngữ và lưu cache.	Tạo 2 chuyên gia tìm kiếm: một bên chuyên từ khóa chính xác, một bên chuyên hiểu ngữ cảnh. Lưu dense_embeddings.pkl.
3. Hợp nhất Hybrid Search	hybrid_retriever.py	Dùng hòa ứng viên của BM25 và Dense bằng Reciprocal Rank Fusion (RRF k=60), tránh cộng điểm thô sai lệch.	Đoạn văn vừa đúng từ khóa vừa sát nghĩa được đưa lên cao nhất, không bị thiên lệch một chiều.
4. Tái xếp hạng Reranker	reranker.py	Dùng Cross-Encoder đọc đồng thời (Câu hỏi + Đoạn văn) để chấm điểm tương quan thực tế.	Đưa điều khoản trả lời trực tiếp lên Top 1. Thấy rõ sự thay đổi giữa bảng Before và After Rerank.
5. Đánh giá Benchmark	compare_retrieval.py	Đo lường định lượng Hit@1, Hit@3, Hit@5 trên tập câu hỏi chuẩn (Keyword, Semantic, Mixed).	Xuất báo cáo evaluation_report.md chứng minh Hybrid + Rerank đạt hiệu năng cao nhất.
6. Mini Knowledge Graph	load_mini_kg.py	Mô hình hóa quan hệ: (:VanBan)-[:CONTAINS]->(:DieuKhoan)-[:NEXT]->(:DieuKhoan) trên Neo4j.	Cung cấp Graph Hints bổ trợ, liên kết điều khoản với văn bản cha và các điều khoản kế tiếp.
7. Streamlit Web App	app.py	Đóng gói pipeline thành giao diện trực quan cho người dùng trải nghiệm tra cứu và so sánh.	Cho phép thử nghiệm 4 mô hình, hiển thị bảng Before/After Rerank và trích dẫn trực tiếp trên web.

3. GIÁ TRỊ CỐT LÕI ĐẠT ĐƯỢC

- Độ chính xác cao: Hợp nhất sức mạnh của tìm kiếm từ khóa cứng và tìm kiếm ngữ nghĩa tự nhiên.
- Minh bạch xuất xứ (Grounding & Citation): Mọi kết quả đều dẫn chứng đầy đủ văn bản, số hiệu, điều khoản cụ thể.
- Sẵn sàng cho Graph RAG nâng cao: Cấu trúc đồ thị chuẩn bị sẵn sàng cho các bài toán suy luận đa bước (Multi-hop).